




Mesures de performances

DSA 2026

UTHAYASOORIYAR Benno / LY Antoine

09/09/2026

Machine Learning

La métrique encode ce que l'on valorise

Choisir une métrique, c'est formaliser le coût métier des erreurs.

MESSAGE CLÉ « MSE vs MAE : une grosse erreur sur un sinistre grave compte-t-elle plus que dix petites erreurs attritionnelles ? » Un choix métier — pas un choix technique.	1.1	Choix métier	15 min
	1.2	Régression	25 min
	1.3	Classification	25 min
	1.4	Ranking	20 min
	1.5	Métriques custom	10 min
	1.6	Exercice pratique	15 min

Choix métier

La métrique dirige le comportement du modèle

De l'objectif business au compromis d'erreurs réellement appris.

OBJECTIF BUSINESS	MÉTRIQUE		COMPORTEMENT DU MODÈLE
1 Minimiser les gros sinistres	MAE pondérée	→	Robuste aux outliers
2 Prédire le coût moyen exact	MSE	→	Sensible aux gros montants
3 Détecter toutes les fraudes	Recall	→	Agressif · davantage de FP
4 Préserver les bons clients	Precision	→	Conservateur · fraudes ratées

Réflexe : nommer le coût d'une erreur avant de choisir la métrique.

Classification

99 % d'accuracy peut correspondre à zéro fraude détectée

100 000 sinistres · 1 % de fraude · prédire toujours « pas fraude ».

99 %

accuracy
apparente

```
def  
modele_naif(sinistre):  
    return "pas fraude"
```

0 fraude détectée

	Prédit fraude	Prédit pas fraude	Total
Vraie fraude	0	1 000	1 000
Pas fraude	0	99 000	99 000
Total	0	100 000	100 000

Accuracy = $99\,000 / 100\,000 = 99\%$

La bonne question : maximiser le recall sous contrainte de precision.

Régression

Chaque métrique de régression privilégie un type d'erreur

Distribution de la cible, outliers et usage actuariel déterminent le bon choix.

MÉTRIQUE	FORMULE COURTE	OUTLIERS	USAGE ACTUARIEL
MSE	$\text{moyenne}(e^2)$	Très sensible	Coût moyen, provisionnement
RMSE	$\sqrt{\text{MSE}}$	Très sensible	Même unité que Y
MAE	$\text{moyenne}(e)$	Robuste	Sévérité, queues lourdes
MAPE	$\text{moyenne}(e/y)$	Variable	Communication métier (%)
R ²	$1 - \text{SSE} / \text{SST}$	Sensible	Pouvoir explicatif global
Poisson dev.	$2 \sum [y \log(y/\hat{y}) - (y - \hat{y})]$	Modérée	Fréquence sinistre

Règle : aligner la métrique sur la distribution et le coût réel de l'erreur.

Régression

MSE et RMSE donnent la priorité aux grandes erreurs

Le carré rend les gros écarts dominants: utile quand ils portent le risque.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\text{RMSE} = \sqrt{\text{MSE}}$$

Une erreur de 100 k€ ne doit pas être traitée comme mille erreurs de 100 €.

Dérivable et convexe

Optimisation stable et rapide.

Lecture statistique

Liée à la vraisemblance gaussienne.

Usage actuariel

Provisionnement : les grosses erreurs comptent.

RMSE remet la métrique dans la même unité que la cible Y.

Régression

MAE protège le signal courant ; MSE laisse les extrêmes piloter

Sur des sévérités à queue lourde, le choix change ce que le modèle apprend.

MAE · pénalité linéaire

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Résidu = 5 → pénalité = 5

Chaque erreur contribue proportionnellement. Les sinistres ordinaires restent visibles.

MSE · pénalité quadratique

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Résidu = 5 → pénalité = 25


Un sinistre corporel très mal prédit peut dominer la métrique et orienter tout le modèle.

Sévérité à queue lourde : MAE est souvent le point de départ le plus robuste.

Régression

La pénalisation quadratique s'écarte vite de la pénalisation linéaire

À partir de résidus modestes, MSE et MAE racontent déjà des histoires différentes.



À résidu 5

MSE = 25

MAE = 5

Les outliers finissent par dominer le signal quadratique.

Régression

MAPE parle en pourcentage, mais échoue dès que la cible vaut zéro

Utile pour communiquer, dangereuse sur les fréquences individuelles.

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|}$$

POURQUOI ELLE SÉDUIT

« Le modèle se trompe en moyenne de 8 % » : une phrase immédiatement compréhensible par le métier.

DEUX PIÈGES



$y_i = 0$

Division par zéro — fréquent quand beaucoup d'assurés n'ont aucun sinistre.



Asymétrie

Sous-prédiction et sur-prédiction ne sont pas pénalisées de façon symétrique.


Bon usage : MAPE agrégée par segment ,pas sur la fréquence individuelle brute.

Régression

R^2 mesure le gain face à la moyenne, pas la valeur métier du modèle

Un faible R^2 peut être normal quand la cible est très bruitée.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\text{MSE du modèle}}{\text{Variance de } Y}$$



$R^2 = 0,30 \rightarrow 30\%$ de la variance expliquée

Auto fréquence : 0,02 à 0,05 peut être normal

Attention : hors échantillon, R^2 peut être négatif.

Régression

Poisson deviance est la métrique naturelle des fréquences de sinistre

Elle garde l'évaluation cohérente avec une cible de comptage et l'exposition.

$$D_{\text{Poisson}} = 2 \sum_{i=1}^n w_i \left[y_i \log \frac{y_i}{\hat{y}_i} - (y_i - \hat{y}_i) \right]$$

Convention : $0 \cdot \log(0) = 0$

≥ 0

Toujours positive

$= 0$

Prédiction parfaite

**Sensible aux
prédictions nulles**

Deviance infinie si $y_i > 0$
et $\hat{y}_i = 0$

w_i

Exposition intégrée

Comptages 0, 1, 2, 3... → une logique de vraisemblance plus pertinente que MSE ou MAE.

Régression

Le bon réflexe : faire correspondre métrique, distribution et risque

Une grille actuarielle pour décider rapidement.

PROBLÈME ACTUARIEL	MÉTRIQUE RECOMMANDÉE	POURQUOI
Fréquence sinistre	Poisson deviance	Distribution de comptage
Sévérité moyenne	MAE ou Gamma deviance	Queues lourdes
Coût total · prime pure	Tweedie deviance	Masse à zéro + queue lourde
Provisionnement	RMSE	Les grandes erreurs comptent
Communication COMEX	MAPE agrégée	Lecture immédiate en %

RÈGLE SIMPLE

Si la distribution est connue, utilisez sa deviance. Sinon, MAE est un robuste point de départ.

Classification

La matrice de confusion est le point de départ

TP, FP, FN et TN traduisent directement les quatre issues opérationnelles.

		PRÉDICTION DU MODÈLE		
		Prédit (+) · fraude	Prédit (-) · légitime	
RÉALITÉ	Réel (+) · fraude	TP Fraude détectée	FN Fraude ratée	Recall TP / (TP + FN)
	Réel (-) · légitime	FP Fausse alerte	TN Légitime correctement payé	
		Precision TP / (TP + FP)	Toutes les métriques de classification partent de ces quatre nombres.	

Classification

Precision et recall répondent à deux questions différentes

L'une juge la qualité des alertes ; l'autre mesure la couverture des fraudes.

PRECISION

$$\frac{TP}{TP + FP}$$

Parmi les cas signalés « fraude », quelle proportion est réellement frauduleuse ?

P(réellement fraude | prédit fraude)

RECALL · SENSIBILITÉ

$$\frac{TP}{TP + FN}$$

Parmi toutes les vraies fraudes, quelle proportion le modèle détecte-t-il ?

P(prédit fraude | réellement fraude)

Seuil ↓ → davantage d'alertes → recall ↑ mais precision ↓

Classification

Le seuil transforme un score en capacité opérationnelle

Il se règle selon le volume d'alertes que l'équipe peut réellement absorber.

SEUIL 0,9 · CONSERVATEUR

95 % precision

20 % recall


Peu d'alertes : on est sûr quand on signale, mais on rate beaucoup.

SEUIL 0,3 · AGRESSIF

30 % precision

90 % recall

Presque toutes les fraudes, au prix de nombreuses fausses alertes.



Exemple : fixer le seuil pour produire environ 500 dossiers à investiguer par mois.

Classification

F1 sanctionne les déséquilibres entre precision et recall

La moyenne harmonique reste faible dès que l'une des deux dimensions s'effondre.

$$F_1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

EXEMPLE DÉSÉQUILIBRÉ

Precision = 0,95

Recall = 0,05

MOYENNE ARITHMÉTIQUE

0,50

Trop optimiste

MOYENNE HARMONIQUE

F₁ = 0,095

Reflète un modèle inutile

Quand le recall est prioritaire :

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \times \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}$$

Classification

Le meilleur modèle dépend de la capacité d'investigation et du coût des erreurs

Sur 100 000 sinistres mensuels, dont 1 000 fraudes.

MODÈLE	PRECISION	RECALL	F1	FP / MOIS	FRAUDES DÉTECTÉES
A • conservateur	85 %	25 %	0,39	44	250
B • équilibré	55 %	60 %	0,57	491	600
C • agressif	20 %	92 %	0,33	4 600	920



≤ 50 dossiers / mois
capacité contrainte



Compromis classique
F1 le plus élevé




Vérification automatisée
rattraper presque tout

Si FN = 50 k€ et FP = 500 €, le calcul économique peut favoriser C malgré un F1 inférieur.

Classification

La ROC évalue le ranking sur tous les seuils

TPR et FPR sont calculés pour chaque seuil de décision, de 0 à 1.



AUC

0,85

Probabilité qu'un positif reçoive un score supérieur à un négatif tiré au hasard.

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN}) = \text{recall}$$

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN}) = 1 - \text{spécificité}$$

AUC = aire sous la courbe ROC

Classification

Le Gini est l’AUC remise à l’échelle

Même ranking, lecture historique en assurance : 0 = aléatoire, 1 = parfait.

$$\text{Gini} = 2 \times \text{AUC} - 1$$

AUC	Gini	Interprétation
0,50	0,00	Modèle aléatoire
0,70	0,40	Modèle faible — mais utile en tarification
0,80	0,60	Bon modèle
0,90	0,80	Très bon modèle — rare en assurance IARD
1,00	1,00	Modèle parfait — impossible en pratique

REPÈRE TARIFICATION AUTO

0,35–0,45

Bon niveau sur la fréquence
sinistre


FRAUDE

viser 0,60+

Classification

Avec 1 % de fraude, la PR révèle ce que la ROC masque

Sa baseline est la prévalence positive, pas 0,5. (cf score F1)



Pourquoi la ROC peut flatter

Avec beaucoup de TN (ex: pas de fraude), le dénominateur du FPR est énorme : même un modèle médiocre conserve un FPR bas.

Pourquoi la PR discrimine

Un modèle aléatoire reste à 1 % de précision quel que soit le recall. Les écarts deviennent immédiatement visibles.


Classification

0,35 → 0,58 : le gain invisible en ROC devient évident en PR

Trois modèles presque équivalents en ROC, mais très différents au regard de la fraude détectée.

Modèle	AUC-ROC	AUC-PR	Commentaire
GBM baseline	0,92	0,35	ROC flatteur, PR révèle les limites
GBM + features	0,94	0,52	Amélioration visible en PR
LightGBM optimisé	0,95	0,58	Meilleur compromis

En contexte déséquilibré, l'AUC-PR est la métrique de référence.



Métriques custom

make_scorer connecte la métrique métier à sklearn

Exemple : optimiser directement la Poisson deviance de fréquence sinistre.

```
import numpy as np
from sklearn.metrics import make_scorer

def poisson_deviance(y_true, y_pred, sample_weight=None):
    """Métrique naturelle pour la fréquence sinistre."""
    y_pred = np.clip(y_pred, 1e-8, None)

    with np.errstate(divide="ignore", invalid="ignore"):
        ratio = np.where(
            y_true > 0,
            y_true * np.log(y_true / y_pred), 0
        )

    deviance = 2 * (ratio - (y_true - y_pred))
    if sample_weight is not None:
        deviance = deviance * sample_weight
    return np.mean(deviance)

poisson_scorer = make_scorer(
    poisson_deviance, greater_is_better=False
)
```

LE POINT CRUCIAL

greater_is_better=False

sklearn suppose qu'un score élevé est meilleur. Pour une deviance à minimiser, il faut inverser le signe.

Compatible avec les poids d'exposition via sample_weight.

Métriques custom

La cross-validation peut enfin optimiser la bonne cible métier

Le meilleur hyperparamétrage n'est plus celui de la MSE, mais celui de la fréquence sinistre.

```
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import GradientBoostingRegressor

param_grid = {
    "max_depth": [3, 5, 7],
    "n_estimators": [100, 200]
}

grid = GridSearchCV(
    GradientBoostingRegressor(),
    param_grid,
    scoring=poisson_scorer,    # métrique custom
    cv=5
)
grid.fit(X_train, y_train)
```

CE QUI CHANGE

6 combinaisons

× 5 folds de validation

Chaque combinaison est classée selon la Poisson deviance — la cible cohérente avec la distribution du nombre de sinistres.

Résultat : le modèle sélectionné est le meilleur pour le risque assuré, pas pour une erreur quadratique générique.

Métriques custom

Le scorer peut encoder directement le coût asymétrique des erreurs

En fraude, un faux négatif à 50 k€ ne vaut pas un faux positif à 500 €.

```
def cout_asymetrique_fraude(
    y_true, y_pred, cout_fn=50000, cout_fp=500
):
    """Coût total des erreurs avec pénalité asymétrique."""
    fn = np.sum((y_true == 1) & (y_pred == 0)) * cout_fn
    fp = np.sum((y_true == 0) & (y_pred == 1)) * cout_fp
    return -(fn + fp)  # score à maximiser

scorer_cout = make_scorer(
    cout_asymetrique_fraude, greater_is_better=True
)
```

L'optimisation devient une décision économique, pas seulement statistique.

RATIO DE COÛT

100×

1 fraude ratée = 100 fausses alertes

CONVENTION

La fonction retourne un coût négatif ;
greater_is_better=True
maximise donc le moins mauvais coût.