




Apprentissage non supervisé

DSA 2026

UTHAYASOORIYAR Benno / LY Antoine

08/09/2026

Supervisé vs non supervisé

Sans variable cible, les données révèlent leur structure

Le supervisé prédit une réponse connue ; le non supervisé explore ce qui n'a pas encore de nom.

APPRENTISSAGE SUPERVISÉ

Prédire

$X \rightarrow y$

Une cible guide l'apprentissage : fréquence, coût, fraude confirmée.

APPRENTISSAGE NON SUPERVISÉ

Explorer

$X \rightarrow \text{structure}$

Aucun label : on découvre des groupes, des axes latents et des profils atypiques.

Apprentissage non supervisé

La session progresse de la compression à la structure

Deux blocs de 1h45 : voir le portefeuille autrement, puis faire émerger ses groupes et ses anomalies.

01

ACP ET RÉDUCTION DE DIMENSION

1h45

Résumer l'information sans perdre l'essentiel —
voir un portefeuille en 2D.

02

CLUSTERING ET DÉTECTION D'OUTLIERS

1h45

Trouver des groupes naturels et repérer ce qui
ne rentre dans aucun groupe.

Explorer → structurer → diagnostiquer → préparer la modélisation

Apprentissage non supervisé

Six compétences pour explorer un portefeuille sans label

L'issue attendue n'est pas un score : c'est une structure interprétable et exploitable.

01 Réduire la dimension avec l'ACP, choisir le nombre de composantes et interpréter les résultats.

02 Segmenter un portefeuille avec K-Means et choisir le nombre de clusters rigoureusement.

03 Appliquer HDBSCAN pour identifier des formes arbitraires et le bruit.

04 Détecter les anomalies avec Isolation Forest et LOF.

05 Interpréter cercles de corrélation, biplots et silhouettes.

06 Articuler exploration non supervisée et modélisation supervisée.

PRÉREQUIS • Pipelines sklearn • StandardScaler • algèbre linéaire • notions de modèles supervisés

Apprentissage non supervisé

Les mêmes briques sklearn, mais une autre logique d'évaluation

StandardScaler et pipelines restent essentiels ; sans vérité terrain, l'inertie et la silhouette remplacent les métriques supervisées.

CE QUE L'ON RÉUTILISE

M03_F01 · Biais–variance La haute dimension aggrave l'overfitting → ACP comme remède

M03_F01 · Pipelines StandardScaler avant l'ACP → étape critique

M03_F05 · Arbres & ensembles K-Means partitionne sans label ; Isolation Forest isole sans cible

M03_F06 · Métriques Pas de vérité terrain → métriques internes

ENVIRONNEMENT

```
Python 3.9+  
scikit-learn · hdbscan  
matplotlib · seaborn
```

DATASETS

freMTPL2freq enrichi	Jeu synthétique
ACP + clustering	Isolation Forest + LOF

```
pip install scikit-learn hdbscan matplotlib  
seaborn
```

Apprentissage non supervisé

Quatre usages, une même promesse : découvrir sans imposer

Les résultats orientent l'analyse et la décision ; ils ne remplacent ni validation métier ni preuve supervisée.

01	SEGMENTER LE PORTEFEUILLE	K-Means / HDBSCAN	Profils-types pour marketing et tarification
02	PROFILER LE RISQUE	ACP + clustering	Axes latents et groupes d'assurés similaires
03	DÉTECTER LA FRAUDE	Isolation Forest / LOF	Sinistres atypiques sans historique labellisé
04	CONTRÔLER LES DONNÉES	Isolation Forest	Erreurs de saisie et anomalies avant modélisation

APRÈS CE BLOC, VOUS NE SEREZ PAS... expert AFC/ACM • prêt à déployer une fraude en production • spécialiste autoencodeurs / VAE

Mais vous aurez les outils fondamentaux et le recul méthodologique pour structurer, détecter et préparer.

Bloc 1

Analyse des Composantes Principales

Apprentissage non supervisé

Six étapes pour résumer l'information sans perdre l'essentiel

De l'intuition de la haute dimension à une ACP interprétable dans un pipeline sklearn.

1.1	20 min	Pourquoi réduire ?	Malédiction de la dimensionnalité
1.2	25 min	ACP : intuition géométrique	Trouver le meilleur angle
1.3	20 min	Formulation mathématique	Covariance, valeurs et vecteurs propres
1.4	20 min	StandardScaler + PCA	Pipeline et bonnes pratiques
1.5	15 min	Visualiser et interpréter	Cercle de corrélation et biplot
1.6	15 min	Exercice pratique	Réduire et commenter un portefeuille

Message clé : 50+ variables → quelques axes principaux → un portefeuille visible en 2D

Réduction de dimension

En haute dimension, les voisins disparaissent


Avec seulement 10 observations, chaque dimension supplémentaire dilue la densité jusqu'à rendre les points quasi équidistants.

d = 1




distance $\approx 0,1$

d = 2



distance $\approx 0,3$

d = 10



distance $\approx 0,9$

d = 50



quasi-équidistants

*(Points tirés aléatoirement, coordonnées i.i.d. uniformes sur $[0,1]$; Les distances moyennes sont des ordres de grandeur illustratifs.
Le phénomène réel sous-jacent est la concentration des distances :
L'écart relatif entre plus proche et plus lointain voisin tend vers 0 quand d augmente.)*

Les algorithmes qui reposent sur la proximité sont perdus: KNN, arbres et clustering

Géométrie

L'hypersphère se vide à mesure que d augmente

En haute dimension, presque tout le volume du cube est dans ses coins : un rayon fixe ne rencontre bientôt plus personne.

VOLUME EN DIMENSION d

$$V_d(r) = \frac{\pi^{d/2}}{\Gamma(d/2 + 1)} \cdot r^d$$

Le terme r^d contracte brutalement le voisinage.

RATIO SPHÈRE / CUBE

$d = 2$	78,5 %	
$d = 5$	16,4 %	
$d = 10$	0,25 %	
$d = 20$	0,000025 %	
$d = 50$	≈ 0 %	

Conséquence actuarielle : 50 features non sélectionnées → données trop éparées → patterns plus difficiles à apprendre.

Modélisation actuarielle

Cinquante variables peuvent créer quatre problèmes à la fois

Les redondances et le bruit gonflent p sans créer d'information nouvelle — la complexité augmente, pas la densité utile.

50 VARIABLES DE TARIFICATION



01 OVERFITTING

Trop de paramètres ; trop peu de données locales.

02 MULTICOLINÉARITÉ

Âge $\leftrightarrow$ ancienneté permis ; BM $\leftrightarrow$ sinistres.

03 BRUIT

Identifiants et dates exactes masquent le signal.

04 COÛT

Certains calculs croissent comme $O(n \cdot p^2)$.



SOLUTION · Réduire p en conservant l'information utile

Réduction de dimension

Deux stratégies : garder des variables ou construire des axes

Le choix oppose interprétabilité directe et conservation maximale de l'information.

SÉLECTION DE VARIABLES

Garder un sous-ensemble des variables originales

Lasso • importance Random Forest

- + Lecture métier immédiate
- Une partie de l'information disparaît

EXTRACTION DE VARIABLES

Créer de nouveaux axes qui résument les originaux

ACP • combinaisons linéaires


- + Information préservée au maximum
- Interprétation directe moins évidente

FOCUS DU BLOC • L'ACP exploite les corrélations pour compresser le portefeuille en quelques axes.

Réduction de dimension

L'ACP cherche le meilleur angle pour "photographier" les données

Une bonne projection "conserve" la forme du nuage. Une mauvaise le compresse.




Le meilleur angle est celui qui maximise la variance projetée (=différence max). Donc l'information conservée.

Réduction de dimension

PC1 est la direction qui étale le plus les projections

Résumer un nuage 2D en une seule dimension revient à choisir la droite la plus informative.

DONNÉES ORIGINALES · 2D



La droite suit la direction principale du nuage.

PROJECTION SUR PC1 · 1D



Projections très étalées


Variance (dispersion) élevée → individus encore distinguables

Si toutes les projections se confondent, la variance tombe — et l'information disparaît.

Réduction de dimension

PC1 capte la tendance principale ; PC2 explique la variance restante

Les composantes successives sont orthogonales, ordonnées et non corrélées.



PROPRIÉTÉS FONDAMENTALES

- 01 PC1 maximise la variance totale projetée.
- 02 PC2 maximise la variance restante avec $PC2 \perp PC1$.
- 03
$$\text{Var}(PC1) \geq \text{Var}(PC2) \geq \text{Var}(PC3) \geq \dots$$
- 04 Les composantes principales sont non corrélées.

L'ACP décompose l'information en couches de variance de plus en plus fines.


Réduction de dimension

L'ACP capture les structures linéaires — pas les spirales

Elle cherche des combinaisons linéaires des variables originales.

ACP ADAPTÉE


ELLIPSOÏDE



Une direction principale résume bien la forme.

ACP INSUFFISANTE

SPIRALE / FORME EN U



Aucune projection linéaire ne déroule la structure.

t-SNE et UMAP traitent le non-linéaire, mais l'ACP reste plus stable et interprétable.

Formulation mathématique

La covariance encode les redondances du portefeuille

Avec n observations et p variables centrées, Σ résume les variations communes.

DÉFINITION

$$\Sigma = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$$

$\mathbf{X} \in \mathbb{R}^{n \times p}$ · données centrées

$\Sigma \in \mathbb{R}^{p \times p}$ · symétrique · semi-définie positive

EXEMPLE DE MATRICE

	Âge	Permis	BM
Âge	1,00	0,88	-0,32
Permis	0,88	1,00	-0,28
BM	-0,32	-0,28	1,00

Diagonale = variances Hors diagonale = covariances

LECTURE ACTUARIELLE

Âge ↔ ancienneté de permis

Covariance élevée
= information redondante
= compression possible

Σ_{jk} mesure comment X_j et X_k évoluent ensemble.

L'ACP exploite les covariances pour remplacer des variables redondantes par quelques axes.

Formulation mathématique

Les vecteurs propres donnent les axes ; les valeurs propres leur importance

L'eigendecomposition construit le nouveau repère de l'ACP.

$$\Sigma = \mathbf{V}\Lambda\mathbf{V}^T$$

VECTEURS PROPRES · directions

$$\mathbf{V} = [v_1 | v_2 | \dots | v_p]$$

- Colonnes orthonormales
- v_1 = direction de variance maximale
- v_2 = meilleure direction orthogonale à v_1

VALEURS PROPRES · variances

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

Chaque λ_k mesure la variance portée par la composante PC_k .


Direction v_k + variance λ_k = une composante principale ordonnée par importance.

Formulation mathématique

Projeter, c'est calculer les scores des assurés

Les nouvelles coordonnées placent chaque individu dans le repère des composantes principales.

$$\mathbf{Z} = \mathbf{XV} \text{ et } z_k = \mathbf{X}v_k$$



La projection conserve les individus ; elle change seulement le repère dans lequel on les observe.

Les composantes principales z_i sont ensuite utilisables comme variables dans la modélisation

Formulation mathématique

La variance expliquée pilote la compression

Choisir k , c'est fixer la quantité d'information conservée et la perte acceptable.

EXEMPLE DE DÉCOMPOSITION



■ PC1 ■ PC2 ■ Reste

PC1 45 % + PC2 25 % = 70 % de variance cumulée

FORMULES & CHOIX DE k

$$\text{Ratio de variance expliquée par PC}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

$$\text{Variance cumulée (k premiers axes)} = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}$$

En pratique : viser 80–95 %
selon le coût acceptable de la perte.

$$\mathbf{X} \approx \mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^T$$

Eckart–Young : meilleure approximation linéaire de rang k au sens de Frobenius.

Exemple : 50 variables → 8 composantes → 90 % de variance conservée · compression ×6.

Mise en pratique

Standardiser avant l'ACP est non négociable

L'ACP maximise la variance : sans scaling, l'unité de mesure décide artificiellement des axes.

SANS StandardScaler

prime_pure



variance = 10 000 000

ratio



variance = 0,02

PC1 $\approx$ prime_pure

PC2 $\approx$ coût_sinistre

→ géométrie dominée par les unités




AVEC StandardScaler

DrivAge




$\sigma^2 = 1$

BonusMalus



$\sigma^2 = 1$

VehPower



$\sigma^2 = 1$

Density



$\sigma^2 = 1$

PC1 = combinaison équilibrée

→ structure réelle du portefeuille

Le scaling corrige les unités: il ne déclare aucune variable métier plus importante qu'une autre.

Mise en pratique

Le pipeline ACP tient en trois transformations

Charger les variables, centrer-réduire, puis garder le minimum d'axes expliquant 95 % de la variance.



```
features = ["DrivAge", "BonusMalus", "VehAge",  
            "VehPower", "Density", "Exposure"]  
X = df[features].values
```

```
X_scaled = StandardScaler().fit_transform(X)  
pca = PCA(n_components=0.95)  
X_pca = pca.fit_transform(X_scaled)
```

SORTIES À CONTRÔLER

Diagnostics

- `X_pca.shape`
- `explained_variance_ratio_`
- variance cumulée


`n_components = 0.95` demande à sklearn le plus petit nombre de composantes qui atteint 95 %.

Mise en pratique

Le scree plot montre où l'information se concentre


Croiser variance par axe et variance cumulée révèle le coude et le seuil utile.

VARIANCE EXPLIQUÉE PAR COMPOSANTE



Coude vers PC3–PC4

VARIANCE CUMULÉE



95 % atteint à PC5

Le coude propose une solution parcimonieuse ; le seuil quantifie l'information conservée.

Mise en pratique

Choisir k exige trois regards complémentaires

Aucun critère ne décide seul : on combine signal statistique, compression et interprétation métier.

01 VARIANCE CUMULÉE

Garder le plus petit k qui atteint 80–95 %.

Mesure directe de l'information conservée.

02 SCREE PLOT

Repérer la rupture de pente (le « coude »).

Favorise une solution parcimonieuse.

03 KAISER

Garder les composantes avec $\lambda_k > 1$.

Chaque axe retenu vaut plus qu'une variable standardisée.

Retenir le plus petit k qui conserve assez d'information sans effacer les signaux rares ni rendre l'analyse illisible.

Points clés

Six réflexes pour une ACP utile en assurance

De la haute dimension à des axes interprétables, puis au clustering.

01 Données éparse La haute dimension fragilise proximité et généralisation.

02 Projection orthogonale PC1 maximise la variance ; les axes suivants sont orthogonaux.

03 StandardScaler Sans scaling, les unités dominant les composantes.

04 Choix de k Croiser seuil 80–95 %, coude et Kaiser.

05 Interprétation Cercle = variables ; biplot = variables + individus.

06 Usage assurance Résumer 50 variables en quelques axes de risque.

À DISCUTER Les 10 % restants cachent-ils une fraude rare ? · L'ACP linéaire capture-t-elle les effets de seuil ?

Suite : utiliser les composantes ACP comme entrée du clustering pour segmenter le portefeuille.

ex1.ipynb


Bloc 2

Clustering

K-MEANS

Les centroïdes se déplacent jusqu'à stabilisation

Même nuage, quatre états successifs.



La solution dépend du point de départ.


HDBSCAN

HDBSCAN cherche des zones denses — et laisse le bruit hors des groupes

Pas de K fixé à l'avance : les régions peu denses deviennent une information.

K-MEANS


« Trouver K centres »



Tous les points sont assignés

HDBSCAN

« Trouver les régions denses »



label -1 = outliers

HDBSCAN

Deux paramètres règlent ce qui mérite le nom de cluster

Plus les seuils montent, moins il reste de groupes et plus le bruit augmente.

1

min_cluster_size

Taille minimale d'un groupe stable

5–100 selon la taille du dataset

2

min_samples

Voisins nécessaires pour estimer la densité

Souvent proche de min_cluster_size

EFFET DE min_cluster_size




Exemple : min_cluster_size = 50 → tout groupe de moins de 50 observations est candidat au bruit.

HDBSCAN

La densité suit les formes arbitraires que les centroïdes découpent mal


Deux croissants, quelques points isolés : un cas classique où la géométrie décide.

K-MEANS · K=2



Coupe l'espace, pas les formes

HDBSCAN



Suit les deux densités + isole le bruit

Résultat : deux clusters non convexes et un ensemble explicite de cas atypiques.

WORKFLOW COMBINÉ

Explorer, isoler les cas atypiques, puis segmenter le portefeuille propre

Les deux algorithmes jouent des rôles successifs, pas concurrents.



1. HDBSCAN sépare ce qui doit être investigué.


2. K-Means résume le cœur du portefeuille.

ISOLATION FOREST · INTUITION


Une anomalie se laisse isoler en très peu de coupures

Les points denses résistent ; les points solitaires cèdent vite.

POINT NORMAL



POINT ANORMAL



Moins de niveaux pour isoler x → score d'anomalie plus élevé

ISOLATION FOREST

Une forêt aléatoire mesure la profondeur d'isolement

Random Forest sans cible : les splits ne sont pas optimisés, ils explorent l'espace.



ÉCHANTILLONNER

$\psi = 256$ points
par arbre

CHOISIR

une feature
aléatoire

COUPER

un seuil entre
[min, max]

RÉPÉTER

jusqu'à 1 point
ou profondeur max

PLUSIEURS ARBRES

Chaque arbre produit une
profondeur $h(x)$.

AGRÉGER

$E[h(x)] =$ profondeur
moyenne

SCORER

Un score d'anomalie
qui diminue avec la profondeur
moyenne

Proche de 1 → point très facile à isoler

LOF : LOCAL OUTLIER FACTOR

LOF repère l'anomalie qui n'est étrange que dans son voisinage

Un point peut sembler normal globalement, mais être trop peu dense localement.


$$\text{LOF}_k(x) = \frac{\text{densité moyenne des } k \text{ voisins de } x}{\text{densité locale de } x}$$

≈ 1 densité comparable $\rightarrow$ normal

$\gg 1$ densité plus faible $\rightarrow$ anomalie locale

< 1 plus dense $\rightarrow$ cœur du cluster

Plus le score est faible, plus le point est anormal.



Grande différence avec l'isolation forest :
LOF détecte les anomalies locales.