



# Apprentissage non supervisé

M03\_F10 · DSA 2026

UTHAYASOORIYAR Benno / LY Antoine

07/09/2026

# Supervisé vs non supervisé

Sans variable cible, les données révèlent leur structure

*Le supervisé prédit une réponse connue ; le non supervisé explore ce qui n'a pas encore de nom.*

## APPRENTISSAGE SUPERVISÉ

### Prédire

$X \rightarrow y$

Une cible guide l'apprentissage : fréquence, coût, fraude confirmée.

## APPRENTISSAGE NON SUPERVISÉ

### Explorer

$X \rightarrow \text{structure}$

Aucun label : on découvre des groupes, des axes latents et des profils atypiques.

# Apprentissage non supervisé

La session progresse de la compression à la structure

*Deux blocs de 1h45 : voir le portefeuille autrement, puis faire émerger ses groupes et ses anomalies.*

## 01 ACP ET RÉDUCTION DE DIMENSION

1h45

Résumer l'information sans perdre l'essentiel — voir un portefeuille en 2D.

## 02 CLUSTERING ET DÉTECTION D'OUTLIERS

1h45

Trouver des groupes naturels et repérer ce qui ne rentre dans aucun groupe.

Explorer → structurer → diagnostiquer → préparer la modélisation

# Apprentissage non supervisé

## Six compétences pour explorer un portefeuille sans label

*L'issue attendue n'est pas un score : c'est une structure interprétable et exploitable.*

**01 Réduire** la dimension avec l'ACP, choisir le nombre de composantes et interpréter les résultats.

**02 Segmenter** un portefeuille avec K-Means et choisir le nombre de clusters rigoureusement.

**03 Appliquer** HDBSCAN pour identifier des formes arbitraires et le bruit.

**04 Détecter** les anomalies avec Isolation Forest et LOF.

**05 Interpréter** cercles de corrélation, biplots et silhouettes.

**06 Articuler** exploration non supervisée et modélisation supervisée.

PRÉREQUIS • Pipelines sklearn • StandardScaler • algèbre linéaire • notions de modèles supervisés

# Apprentissage non supervisé

Les mêmes briques sklearn, mais une autre logique d'évaluation

*StandardScaler et pipelines restent essentiels ; sans vérité terrain, l'inertie et la silhouette remplacent les métriques supervisées.*

## CE QUE L'ON RÉUTILISE

**M03\_F01 · Biais–variance** La haute dimension aggrave l'overfitting → ACP comme remède

**M03\_F01 · Pipelines** StandardScaler avant l'ACP → étape critique

**M03\_F05 · Arbres & ensembles** K-Means partitionne sans label ; Isolation Forest isole sans cible

**M03\_F06 · Métriques** Pas de vérité terrain → métriques internes

## ENVIRONNEMENT

```
Python 3.9+
scikit-learn · hdbscan
matplotlib · seaborn
```

## DATASETS

|                      |                        |
|----------------------|------------------------|
| freMTPL2freq enrichi | Jeu synthétique        |
| ACP + clustering     | Isolation Forest + LOF |

```
pip install scikit-learn hdbscan matplotlib
seaborn
```

# Apprentissage non supervisé

## Quatre usages, une même promesse : découvrir sans imposer

*Les résultats orientent l'analyse et la décision ; ils ne remplacent ni validation métier ni preuve supervisée.*

|    |                           |                        |                                                   |
|----|---------------------------|------------------------|---------------------------------------------------|
| 01 | SEGMENTER LE PORTEFEUILLE | K-Means / HDBSCAN      | Profils-types pour marketing et tarification      |
| 02 | PROFILER LE RISQUE        | ACP + clustering       | Axes latents et groupes d'assurés similaires      |
| 03 | DÉTECTER LA FRAUDE        | Isolation Forest / LOF | Sinistres atypiques sans historique labellisé     |
| 04 | CONTRÔLER LES DONNÉES     | Isolation Forest       | Erreurs de saisie et anomalies avant modélisation |

**APRÈS CE BLOC, VOUS NE SEREZ PAS...** expert AFC/ACM • prêt à déployer une fraude en production • spécialiste autoencodeurs / VAE

**Mais vous aurez les outils fondamentaux et le recul méthodologique pour structurer, détecter et préparer.**

# Bloc 1

Comment fonctionne le `.fit()` ?

# Apprentissage non supervisé

## Six étapes pour résumer l'information sans perdre l'essentiel

*De l'intuition de la haute dimension à une ACP interprétable dans un pipeline sklearn.*

|     |        |                                    |                                         |
|-----|--------|------------------------------------|-----------------------------------------|
| 1.1 | 20 min | <b>Pourquoi réduire ?</b>          | Malédiction de la dimensionnalité       |
| 1.2 | 25 min | <b>ACP : intuition géométrique</b> | Trouver le meilleur angle               |
| 1.3 | 20 min | <b>Formulation mathématique</b>    | Covariance, valeurs et vecteurs propres |
| 1.4 | 20 min | <b>StandardScaler + PCA</b>        | Pipeline et bonnes pratiques            |
| 1.5 | 15 min | <b>Visualiser et interpréter</b>   | Cercle de corrélation et biplot         |
| 1.6 | 15 min | <b>Exercice pratique</b>           | Réduire et commenter un portefeuille    |

**Message clé : 50+ variables → quelques axes principaux → un portefeuille visible en 2D**



# Réduction de dimension

## En haute dimension, les voisins disparaissent


*Avec seulement 10 observations, chaque dimension supplémentaire dilue la densité jusqu'à rendre les points quasi équidistants.*

**d = 1**




distance  $\approx 0,1$

**d = 2**



distance  $\approx 0,3$

**d = 10**



distance  $\approx 0,9$

**d = 50**



quasi-équidistants

*(Points tirés aléatoirement, coordonnées i.i.d. uniformes sur  $[0,1]$  ; Les distances moyennes sont des ordres de grandeur illustratifs.  
Le phénomène réel sous-jacent est la concentration des distances :  
L'écart relatif entre plus proche et plus lointain voisin tend vers 0 quand d augmente.)*

**Les algorithmes qui reposent sur la proximité sont perdus: KNN, arbres et clustering**

# Géométrie

## L'hypersphère se vide à mesure que $d$ augmente

*En haute dimension, presque tout le volume du cube est dans ses coins : un rayon fixe ne rencontre bientôt plus personne.*

### VOLUME EN DIMENSION $d$

$$V_d(r) = \frac{\pi^{d/2}}{\Gamma(d/2 + 1)} \cdot r^d$$

Le terme  $r^d$  contracte brutalement le voisinage.

### RATIO SPHÈRE / CUBE

|          |               |                                                                                     |
|----------|---------------|-------------------------------------------------------------------------------------|
| $d = 2$  | 78,5 %        |  |
| $d = 5$  | 16,4 %        |  |
| $d = 10$ | 0,25 %        |  |
| $d = 20$ | 0,000025 %    |  |
| $d = 50$ | $\approx 0$ % |  |

**Conséquence actuarielle : 50 features non sélectionnées → données trop éparées → patterns plus difficiles à apprendre.**

# Modélisation actuarielle

Cinquante variables peuvent créer quatre problèmes à la fois

*Les redondances et le bruit gonflent  $p$  sans créer d'information nouvelle — la complexité augmente, pas la densité utile.*

## 50 VARIABLES DE TARIFICATION



### 01 OVERFITTING

Trop de paramètres ; trop peu de données locales.

### 02 MULTICOLINÉARITÉ

Âge  $\leftrightarrow$  ancienneté permis ; BM  $\leftrightarrow$  sinistres.

### 03 BRUIT

Identifiants et dates exactes masquent le signal.

### 04 COÛT

Certains calculs croissent comme  $O(n \cdot p^2)$ .



**SOLUTION** · Réduire  $p$  en conservant l'information utile

# Réduction de dimension

Deux stratégies : garder des variables ou construire des axes

*Le choix oppose interprétabilité directe et conservation maximale de l'information.*

## SÉLECTION DE VARIABLES

### Garder un sous-ensemble des variables originales

Lasso • importance Random Forest

- + Lecture métier immédiate
- Une partie de l'information disparaît

## EXTRACTION DE VARIABLES

### Créer de nouveaux axes qui résument les originaux

ACP • combinaisons linéaires


- + Information préservée au maximum
- Interprétation directe moins évidente

**FOCUS DU BLOC • L'ACP exploite les corrélations pour compresser le portefeuille en quelques axes.**

# Réduction de dimension

L'ACP cherche le meilleur angle pour "photographier" les données

*Une bonne projection "conserve" la forme du nuage. Une mauvaise le compresse.*




**Le meilleur angle est celui qui maximise la variance projetée (=différence max). Donc l'information conservée.**

# Réduction de dimension

PC1 est la direction qui étale le plus les projections

*Résumer un nuage 2D en une seule dimension revient à choisir la droite la plus informative.*

DONNÉES ORIGINALES · 2D



*La droite suit la direction principale du nuage.*

PROJECTION SUR PC1 · 1D



**Projections très étalées**


Variance (dispersion) élevée → individus encore distinguables

**Si toutes les projections se confondent, la variance tombe — et l'information disparaît.**

# Réduction de dimension

PC1 capte la tendance principale ; PC2 explique la variance restante

*Les composantes successives sont orthogonales, ordonnées et non corrélées.*



## PROPRIÉTÉS FONDAMENTALES

- 01 PC1 maximise la variance totale projetée.
- 02 PC2 maximise la variance restante avec  $PC2 \perp PC1$ .
- 03  $Var(PC1) \geq Var(PC2) \geq Var(PC3) \geq \dots$
- 04 Les composantes principales sont non corrélées.

L'ACP décompose l'information en couches de variance de plus en plus fines.


# Réduction de dimension

L'ACP capture les structures linéaires — pas les spirales

*Elle cherche des combinaisons linéaires des variables originales.*

## ACP ADAPTÉE


### ELLIPSOÏDE



Une direction principale résume bien la forme.

## ACP INSUFFISANTE

### SPIRALE / FORME EN U



Aucune projection linéaire ne déroule la structure.

**t-SNE et UMAP traitent le non-linéaire, mais l'ACP reste plus stable et interprétable.**



# Formulation mathématique

## La covariance encode les redondances du portefeuille

Avec  $n$  observations et  $p$  variables centrées,  $\Sigma$  résume les variations communes.

### DÉFINITION

$$\Sigma = \frac{1}{n-1} \mathbf{X}^T \mathbf{X}$$

$\mathbf{X} \in \mathbb{R}^{n \times p}$  · données centrées

$\Sigma \in \mathbb{R}^{p \times p}$  · symétrique · semi-définie positive

### EXEMPLE DE MATRICE

|        | Âge   | Permis | BM    |
|--------|-------|--------|-------|
| Âge    | 1,00  | 0,88   | -0,32 |
| Permis | 0,88  | 1,00   | -0,28 |
| BM     | -0,32 | -0,28  | 1,00  |

Diagonale = variances    Hors diagonale = covariances

### LECTURE ACTUARIELLE

**Âge ↔ ancienneté de permis**

Covariance élevée  
= information redondante  
= compression possible

$\Sigma_{jk}$  mesure comment  $X_j$  et  $X_k$  évoluent ensemble.

L'ACP exploite les covariances pour remplacer des variables redondantes par quelques axes.

# Formulation mathématique

Les vecteurs propres donnent les axes ; les valeurs propres leur importance

*L'eigendecomposition construit le nouveau repère de l'ACP.*

$$\Sigma = \mathbf{V}\Lambda\mathbf{V}^T$$

## VECTEURS PROPRES · directions

$$\mathbf{V} = [v_1 | v_2 | \dots | v_p]$$

- Colonnes orthonormales
- $v_1$  = direction de variance maximale
- $v_2$  = meilleure direction orthogonale à  $v_1$

## VALEURS PROPRES · variances

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_p)$$

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$$

Chaque  $\lambda_k$  mesure la variance portée par la composante  $PC_k$ .


**Direction  $v_k$  + variance  $\lambda_k$  = une composante principale ordonnée par importance.**

# Formulation mathématique

Projeter, c'est calculer les scores des assurés

*Les nouvelles coordonnées placent chaque individu dans le repère des composantes principales.*

$$\mathbf{Z} = \mathbf{XV} \text{ et } z_k = \mathbf{X}v_k$$



La projection conserve les individus ; elle change seulement le repère dans lequel on les observe.

Les composantes principales  $z_i$  sont ensuite utilisables comme variables dans la modélisation

# Formulation mathématique

## La variance expliquée pilote la compression

*Choisir k, c'est fixer la quantité d'information conservée et la perte acceptable.*

### EXEMPLE DE DÉCOMPOSITION



■ PC1 ■ PC2 ■ Reste

**PC1 45 % + PC2 25 % = 70 % de variance cumulée**

### FORMULES & CHOIX DE k

$$\text{Ratio de variance expliquée par PC}_k = \frac{\lambda_k}{\sum_{j=1}^p \lambda_j}$$

$$\text{Variance cumulée (k premiers axes)} = \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j}$$

En pratique : viser 80–95 %  
selon le coût acceptable de la perte.

$$\mathbf{X} \approx \mathbf{X}_k = \mathbf{Z}_k \mathbf{V}_k^T$$

Eckart–Young : meilleure approximation linéaire de rang k au sens de Frobenius.

**Exemple : 50 variables → 8 composantes → 90 % de variance conservée · compression ×6.**

# Mise en pratique

## Standardiser avant l'ACP est non négociable

*L'ACP maximise la variance : sans scaling, l'unité de mesure décide artificiellement des axes.*

### SANS StandardScaler

prime\_pure



variance = 10 000 000

ratio



variance = 0,02

PC1  $\approx$  prime\_pure

PC2  $\approx$  coût\_sinistre

→ géométrie dominée par les unités



### AVEC StandardScaler

DrivAge



$\sigma^2 = 1$

BonusMalus



$\sigma^2 = 1$

VehPower



$\sigma^2 = 1$

Density



$\sigma^2 = 1$

PC1 = combinaison équilibrée

→ structure réelle du portefeuille

**Le scaling corrige les unités: il ne déclare aucune variable métier plus importante qu'une autre.**

# Mise en pratique

## Le pipeline ACP tient en trois transformations

*Charger les variables, centrer-réduire, puis garder le minimum d'axes expliquant 95 % de la variance.*



```
features = ["DrivAge", "BonusMalus", "VehAge",  
            "VehPower", "Density", "Exposure"]  
X = df[features].values
```

```
X_scaled = StandardScaler().fit_transform(X)  
pca = PCA(n_components=0.95)  
X_pca = pca.fit_transform(X_scaled)
```

### SORTIES À CONTRÔLER

#### Diagnostics

- `X_pca.shape`
- `explained_variance_ratio_`
- variance cumulée


**`n_components = 0.95` demande à sklearn le plus petit nombre de composantes qui atteint 95 %.**

# Mise en pratique

Le scree plot montre où l'information se concentre


*Croiser variance par axe et variance cumulée révèle le coude et le seuil utile.*

## VARIANCE EXPLIQUÉE PAR COMPOSANTE



Coude vers PC3–PC4

## VARIANCE CUMULÉE



95 % atteint à PC5

Le coude propose une solution parcimonieuse ; le seuil quantifie l'information conservée.

# Mise en pratique

## Choisir k exige trois regards complémentaires

*Aucun critère ne décide seul : on combine signal statistique, compression et interprétation métier.*

### 01 VARIANCE CUMULÉE

**Garder le plus petit k qui atteint 80–95 %.**

Mesure directe de l'information conservée.

### 02 SCREE PLOT

**Repérer la rupture de pente (le « coude »).**

Favorise une solution parcimonieuse.

### 03 KAISER

**Garder les composantes avec  $\lambda_k > 1$ .**

Chaque axe retenu vaut plus qu'une variable standardisée.

**Retenir le plus petit k qui conserve assez d'information sans effacer les signaux rares ni rendre l'analyse illisible.**



# Points clés

## Six réflexes pour une ACP utile en assurance

*De la haute dimension à des axes interprétables, puis au clustering.*

**01 Données éparses** La haute dimension fragilise proximité et généralisation.

**02 Projection orthogonale** PC1 maximise la variance ; les axes suivants sont orthogonaux.

**03 StandardScaler** Sans scaling, les unités dominent les composantes.

**04 Choix de k** Croiser seuil 80–95 %, coude et Kaiser.

**05 Interprétation** Cercle = variables ; biplot = variables + individus.

**06 Usage assurance** Résumer 50 variables en quelques axes de risque.

**À DISCUTER** Les 10 % restants cachent-ils une fraude rare ? · L'ACP linéaire capture-t-elle les effets de seuil ?

**Suite : utiliser les composantes ACP comme entrée du clustering pour segmenter le portefeuille.**

**ex1.ipynb**


# Bloc 2

# Clustering

# K-MEANS

Les centroïdes se déplacent jusqu'à stabilisation

*Même nuage, quatre états successifs.*



La solution dépend du point de départ.


# HDBSCAN

HDBSCAN cherche des zones denses — et laisse le bruit hors des groupes

*Pas de K fixé à l'avance : les régions peu denses deviennent une information.*

## K-MEANS


« Trouver K centres »



Tous les points sont assignés

## HDBSCAN

« Trouver les régions denses »



label -1 = outliers

# HDBSCAN

## Deux paramètres règlent ce qui mérite le nom de cluster

*Plus les seuils montent, moins il reste de groupes et plus le bruit augmente.*

1

**min\_cluster\_size**

**Taille minimale d'un groupe stable**

5–100 selon la taille du dataset

2

**min\_samples**

**Voisins nécessaires pour estimer la densité**

Souvent proche de min\_cluster\_size

### EFFET DE min\_cluster\_size




Exemple : min\_cluster\_size = 50 → tout groupe de moins de 50 observations est candidat au bruit.

# HDBSCAN

La densité suit les formes arbitraires que les centroïdes découpent mal


*Deux croissants, quelques points isolés : un cas classique où la géométrie décide.*

K-MEANS · K=2



Coupe l'espace, pas les formes

HDBSCAN



Suit les deux densités + isole le bruit

**Résultat : deux clusters non convexes et un ensemble explicite de cas atypiques.**

## WORKFLOW COMBINÉ

# Explorer, isoler les cas atypiques, puis segmenter le portefeuille propre

*Les deux algorithmes jouent des rôles successifs — pas concurrents.*



**1. HDBSCAN sépare ce qui doit être investigué.**

**2. K-Means résume le cœur du portefeuille.**




# ISOLATION FOREST · INTUITION


Une anomalie se laisse isoler en très peu de coupures

*Les points denses résistent ; les points solitaires cèdent vite.*

POINT NORMAL



POINT ANORMAL



Moins de niveaux pour isoler x → score d'anomalie plus élevé

# ISOLATION FOREST

## Une forêt aléatoire mesure la profondeur d'isolement

*Random Forest sans cible : les splits ne sont pas optimisés, ils explorent l'espace.*



### ÉCHANTILLONNER

$\psi = 256$  points  
par arbre

### CHOISIR

une feature  
aléatoire

### COUPER

un seuil entre  
[min, max]

### RÉPÉTER

jusqu'à 1 point  
ou profondeur max

### PLUSIEURS ARBRES

Chaque arbre produit une  
profondeur  $h(x)$ .

### AGRÉGER

$E[h(x)] =$  profondeur  
moyenne

### SCORER

**Un score d'anomalie**  
qui diminue avec la profondeur  
moyenne

Proche de 1 → point très facile à isoler

# LOF : LOCAL OUTLIER FACTOR


LOF repère l'anomalie qui n'est étrange que dans son voisinage

*Un point peut sembler normal globalement, mais être trop peu dense localement.*

$$\text{LOF}_k(x) = \frac{\text{densité moyenne des } k \text{ voisins de } x}{\text{densité locale de } x}$$

- $\approx 1$  densité comparable  $\rightarrow$  normal
- $\gg 1$  densité plus faible  $\rightarrow$  anomalie locale
- $< 1$  plus dense  $\rightarrow$  cœur du cluster

*Plus le score est faible, plus le point est anormal.*



**Grande différence avec l'isolation forest :**  
**LOF détecte les anomalies locales.**